

Actividad 4 - Introducción Ciencia de Datos

Daniel Rodriguez, Camilo Daza & Sebastian Morelli

Mayo de 2022

Motivación

Las necesidades ambientales han requerido un cambio a energías renovables, como eólica y solar. Aun así, nuestra infraestructura actual no se ajusta a las necesidades específicas de estas energías verdes. Gracias a esto, se pueden presentar problemas que impiden usar estos métodos sostenibles a su máximo potencial.

En el caso de la energía solar, existen granjas de paneles solares cuyo propósito es producir energía limpia a gran escala. Sin embargo, pueden existir problemas asociados a polvo en los paneles, paneles agrietados, sombra parcial, etc. Por lo tanto, es ideal desarrollar métodos computacionales que puedan detectar estos problemas de manera automática y, de esta manera, solucionarlos sin demora.

Desarrollo

El análisis de los problemas en los paneles solares puede separarse en dos etapas:

1. Identificación de los paneles solares.
2. Identificación del tipo de problema en el panel.

Identificación de los paneles solares

Sin embargo, el paso más importante es la identificación de los paneles solares, pues una vez identificados se puede proceder a determinar las características de cada uno de los tipos de problemas. Así, nos limitaremos a la identificación de los paneles. Para la identificación adecuada de los paneles solares, se trabaja con una red neuronal convolucional que, mediante segmentación semántica, pueda

identificar las partes de cada imagen donde se encuentra el panel.

Este proceso de segmentación de imágenes involucra la clasificación de cada uno de los píxeles en la imagen para determinar la forma y tipo de objeto al cual este pertenece.

El conjunto de datos que utilizamos en el programa puede encontrarse en el [siguiente link](#). Este conjunto de datos contiene distintas imágenes satelitales con paneles solares visibles. De esta manera, es posible separar en conjuntos de entrenamiento, prueba y validación.

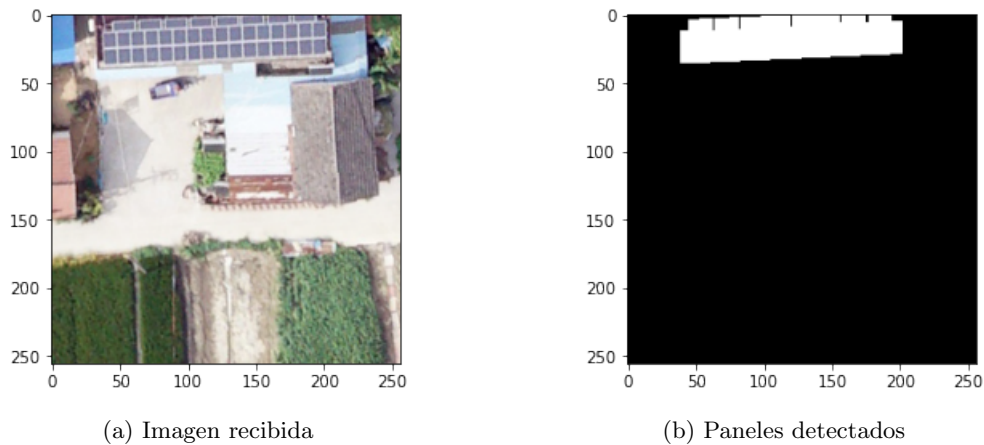


Figura 1: Proceso de detección de paneles en las imágenes.

Ahora bien, recuerde que las redes neuronales convolucionales están compuestas por múltiples neuronas, donde cada neurona tiene se especializa en el reconocimiento de un determinado punto de la imagen. Así, para nuestro caso de paneles solares, existen diferentes capas para una detección exitosa. La primera capa se encarga de la detección de la parte del panel bajo el sol, la segunda encuentra los bordes de los paneles. De esta manera, unir toda esta información permite determinar la ubicación del panel y las posiciones de cada uno de sus componentes.

Para este problemas se van a realizar dos aproximaciones: La primera es el uso de dos redes neuronales pre-entrenadas, **Unet** y **Mobile net**. Esto nos permite tomar los pesos ya definidos por mobile net y, usando el conjunto de datos nuevo, modificar los pesos definidos anteriormente por U-net. A continuación se observa la topología de red.

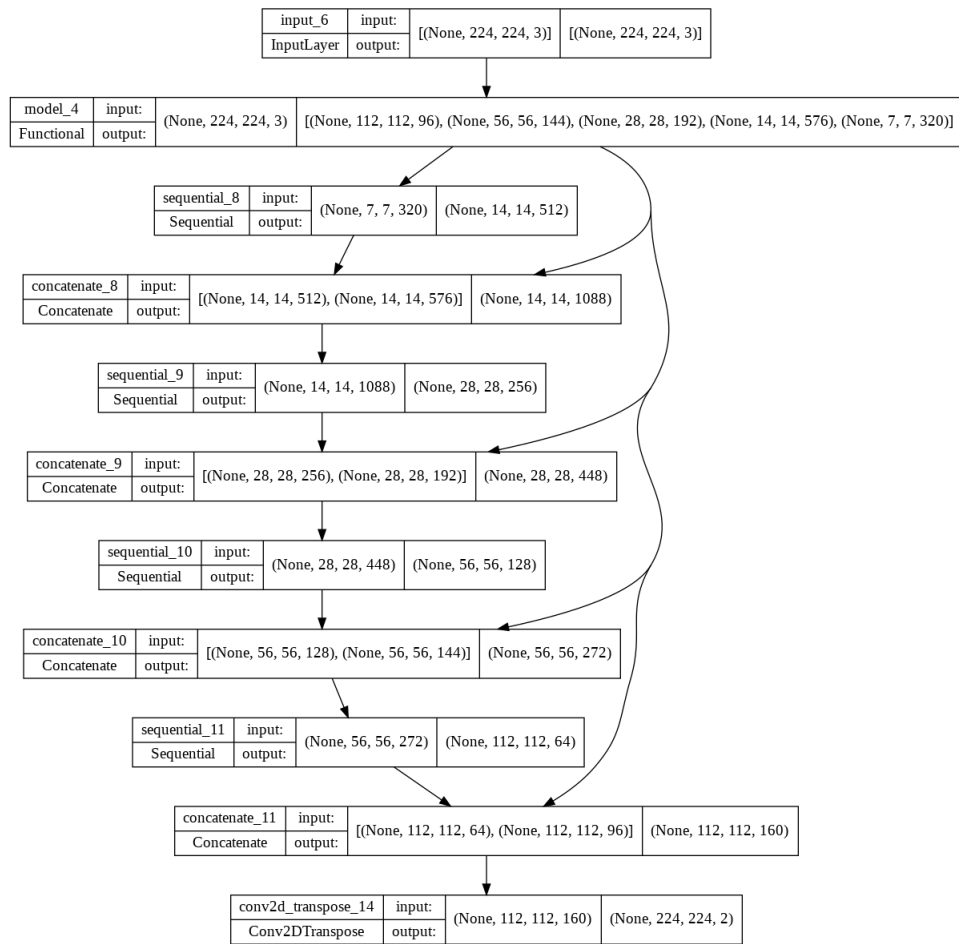


Figura 2: Arquitectura de la red preentrenada.

Para el entrenamiento se utilizó Adam como optimizador, con un tamaño de batch (batch size) de 32, sin añadir regularización o dropout. Es importante resaltar que se realizó regularización sobre los datos. Esto quiere decir que las imágenes, que son matrices que contienen valores de 0 a 255, pasaron a tener valores en el intervalo de 0 a 1; esto con el objetivo de que el optimizador tenga una mejor convergencia. Al hacer el proceso de fine tuning o de entrenamiento con la segunda parte de la red convolucional (u-net), se tuvieron los siguientes resultados.




Figura 3: Entrenamiento de la red preentrenada.

Se puede observar que gracias al pre entrenamiento el modelo tiene un buen comportamiento a la hora de la predicción, ya que al pasar de las épocas, el accuracy se va mejorando gradualmente. Esto es muy positivo, pues se muestran mejorías tanto en el conjunto de entrenamiento como en el conjunto de validación. Lo que indica que el modelo tiene una generalidad bastante buena, pues también tiene buen desempeño con un conjunto que no es con el que fue entrenado.

La segunda aproximación para solucionar el problema, consiste en una topología de red propuesta por nosotros. En ella se destacan capas de UpSampling de la matriz, que básicamente replica los elementos de las matrices que se ingresan aumentando la dimensionalidad. Igualmente, la convolución transpuesta que hace un proceso opuesto a la convolución de modo que se aumenta la dimensionalidad de la matriz. Todo esto con el objetivo que la salida de la red tenga la misma dimensión que la matriz de entrada. A continuación se expone la topología de la red.

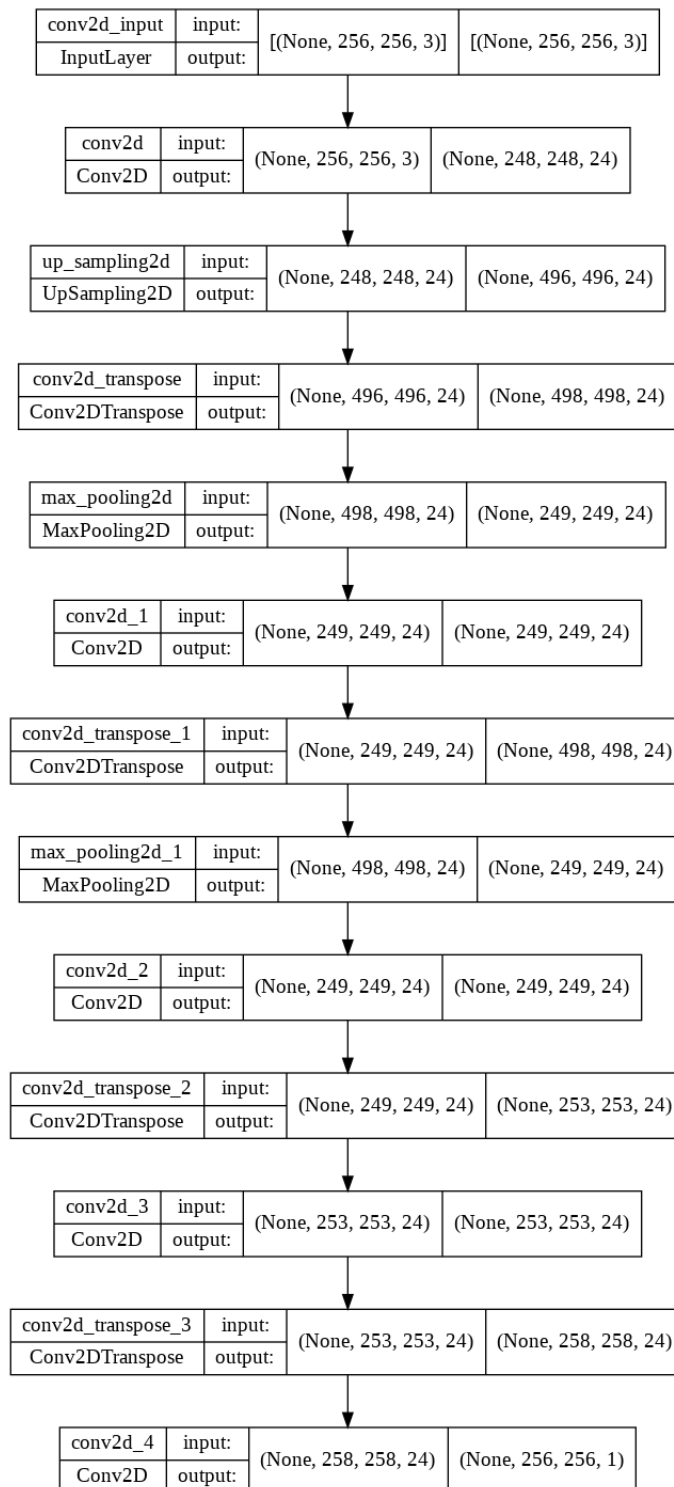


Figura 4: Arquitectura de la red propia.

Para esta topología de red no se tuvieron buenos resultados, pues el principal problema fue que la

capa de salida arrojaba que toda la matriz era cero. Esto quiere decir que no aprendía exitosamente, pues indicaba que no habían paneles solares en ningún píxel de la imagen de entrada.

A manera de conclusión, es una mejor idea trabajar con redes pre-entrenadas, pues a pesar de que pueden tener una gran dimensionalidad de parámetros, fueron entrenadas con muchos datos, por lo que para nuestro problema en específico sólo se hace necesario entrenar las últimas capas de esta red. Por su parte, cuando se entrena una red desde cero se debe intentar variando todos los hiperparámetros para obtener un mejor desempeño, esto puede ser un trabajo muy extenso y que requiere de mucho tiempo y recursos computacionales.